

EXPLAINABLE AI (XAI)

Da resposta convincente à decisão defensável

Um guia de consulta sobre explicabilidade, evidência e governança de Inteligência Artificial

IMPORTANTE: Este material tem finalidade educacional. Questões jurídicas, regulatórias e setoriais precisam ser avaliadas conforme o contexto de cada organização.

Boas-vindas

A Inteligência Artificial está presente em decisões, análises e interações cada vez mais comuns. Ela classifica documentos, recomenda produtos, estima riscos, identifica padrões, escreve textos e ajuda a organizar grandes volumes de informação. Em muitos casos, a qualidade da resposta impressiona. O texto parece seguro, o gráfico é convincente e a probabilidade aparece com precisão aparente. [3]

Mas uma resposta convincente não é necessariamente uma resposta confiável.

É justamente nesse espaço — entre aquilo que parece correto e aquilo que pode ser verificado — que entra a **Explainable AI**, ou simplesmente **XAI**. Em português, o termo costuma aparecer como Inteligência Artificial Explicável. Mais do que um conjunto de gráficos ou ferramentas, XAI reúne formas de investigar como um sistema funciona, quais fatores influenciam seus resultados, onde estão seus limites e que tipo de confiança faz sentido depositar nele. [1][2]

O programa XAI da DARPA ajudou a consolidar essa área ao buscar modelos capazes de oferecer explicações úteis sem abandonar um nível relevante de desempenho [1]. O NIST acrescenta quatro ideias importantes: o sistema deve oferecer razões ou evidências; a explicação precisa fazer sentido para quem a recebe; deve representar corretamente o processo do sistema; e precisa reconhecer os próprios limites [2].

Este guia mantém os pés no ambiente real das organizações. Uma decisão apoiada por IA não nasce apenas do modelo. Ela envolve dados, regras de negócio, interfaces, processos, pessoas, fornecedores, políticas e responsabilidades. Uma boa explicação precisa conversar com todo esse conjunto.

A leitura pode ser retomada sempre que surgir uma dúvida. Não é necessário seguir uma sequência rígida. Os capítulos iniciais apresentam a base conceitual; os seguintes percorrem métodos, tecnologias, validação, riscos, governança e estratégia. As tecnologias são mencionadas como caminhos possíveis, sem exemplos de código, para que implementações próprias possam ser acrescentadas depois com o contexto adequado.

1. Quando uma resposta não basta

A sedução da fluência

Uma frase bem construída reduz o esforço de leitura. Um gráfico organizado facilita a interpretação. Uma recomendação escrita em tom seguro pode parecer resultado de uma análise profunda. Esses elementos são úteis, mas também podem nos levar a aceitar uma conclusão antes de verificar sua origem. [20]

Modelos de linguagem tornam essa questão especialmente visível. Eles são muito bons em produzir textos coerentes e adequados ao contexto, mas a qualidade da escrita não garante a qualidade dos fatos. Da mesma forma, um modelo preditivo pode produzir uma probabilidade com aparência precisa sem que isso demonstre que os dados são atuais, que a população analisada corresponde ao uso real ou que o número foi corretamente calibrado. [20][22]

Ideia	O que ela revela	O que ainda falta
Fluência	A mensagem está clara e bem escrita	Confirmar conteúdo e origem
Plausibilidade	A resposta parece coerente	Verificar se a hipótese corresponde aos fatos
Evidência	Há dados, fontes e lógica que podem ser conferidos	Avaliar se a evidência é suficiente para agir
Decisão	Existe uma ação definida	Identificar regra, autoridade e responsabilidade

Uma resposta pode ser fluente e falsa. Pode ser plausível e não ter evidência. Pode estar sustentada por dados e, ainda assim, não autorizar determinada decisão. O salto entre “o modelo indicou” e “a organização decidiu” merece atenção. [3]

Cinco perguntas que mudam a conversa

Quando a saída de uma IA começa a influenciar uma decisão, cinco perguntas ajudam a colocar o resultado no lugar certo:

1. Qual é a fonte oficial?
2. Qual modelo, cálculo ou regra foi aplicado?
3. O que acontece se a resposta estiver errada?
4. Quem pode revisar e decidir?
5. Onde estão os registros que permitem reconstruir o processo?

Uma recomendação sem fonte é apenas uma afirmação. Uma probabilidade sem contexto é apenas um número. Uma decisão sem responsável é um risco organizacional. [3]

Estimativa, política e responsabilidade

Imagine um sistema de crédito. O modelo estima a probabilidade de atraso. A política da empresa define como diferentes faixas de risco devem ser tratadas. Regras complementares verificam documentação, limites e impedimentos. Uma pessoa ou instância autorizada responde pela decisão final.

O modelo estima; a política estabelece critérios; as regras aplicam condições explícitas; a explicação ajuda a compreender e investigar; a supervisão trata exceções; e a governança define quem responde pelo conjunto. [3]

Quando essas funções ficam misturadas, uma saída estatística pode ser tratada como ordem. Separá-las torna o sistema mais compreensível e permite alterar uma política sem fingir que o modelo “aprendeu” uma nova regra.

Um número não é um veredito

Uma probabilidade de 0,82 não significa que determinada pessoa “é 82% inadimplente”. Ela representa a estimativa de um modelo para um evento definido, dentro de uma janela temporal, com base em dados e condições específicas. O significado depende da definição do alvo, da população de treinamento, da qualidade dos rótulos, da calibração e do momento em que a inferência foi realizada. [22]

Classificadores bem calibrados procuram fazer com que grupos de previsões próximas de 0,8 correspondam aproximadamente a 80% de resultados positivos observados. Isso ainda não transforma a probabilidade em certeza individual [22]. ainda não transforma a probabilidade em certeza individual. Apenas torna sua leitura estatística mais consistente.

O começo da explicabilidade

XAI costuma ser associada ao momento em que um gráfico é gerado. Na realidade, a explicabilidade começa antes do treinamento. Ela aparece na forma como o problema é definido, nos dados escolhidos, nos limites do uso, no público afetado e na decisão sobre o que o sistema poderá fazer. [3]

Uma explicação colocada no final do projeto não corrige uma pergunta mal formulada. Ela pode, no máximo, tornar o problema mais visível.

DICA: Os quatro princípios de explicabilidade do NIST são um bom ponto de partida para compreender por que explicação, compreensão, fidelidade e limites precisam aparecer juntas [2].

2. O que realmente significa explicar uma IA

Quatro conceitos próximos

Interpretabilidade, explicabilidade, transparência e rastreabilidade aparecem frequentemente como sinônimos. Eles se relacionam, mas respondem a perguntas diferentes.

Conceito	Pergunta principal	Exemplo de evidência
Interpretabilidade	É possível entender diretamente o mecanismo?	Coeficientes, regras ou árvore curta
Explicabilidade	Que fatores ajudam a compreender este comportamento?	SHAP, LIME ou contrafactual
Transparência	O que é o sistema e quais são seus limites?	Documentação e Model Card
Rastreabilidade	É possível reconstruir o que aconteceu?	Linhagem, versões e registros

Interpretabilidade

Um modelo é interpretável quando seu funcionamento pode ser compreendido diretamente em um nível útil. Uma regressão com poucas variáveis, uma árvore curta ou uma lista de regras podem permitir que o mecanismo seja acompanhado sem a necessidade de um segundo modelo explicador. [16][26]

Isso não significa que o modelo esteja correto. Uma regra pode ser injusta de maneira transparente. Uma regressão pode usar dados enviesados. A interpretabilidade facilita a inspeção, mas não substitui a validação. [26]

Explicabilidade

Explicabilidade não é apenas uma propriedade do modelo. É uma relação entre uma pergunta, uma explicação e alguém que precisa utilizá-la. Um gráfico de contribuições pode ser útil para investigar um erro técnico, mas confuso para uma pessoa que deseja entender por que seu pedido foi recusado. [2][19]

Por isso, a primeira pergunta não deveria ser “qual ferramenta de XAI será usada?”, mas “o que precisa ser compreendido e para qual finalidade?”. Diagnóstico, validação, atendimento, contestação e auditoria pedem explicações diferentes.

Transparência

Transparência inclui a finalidade do sistema, seus responsáveis, os dados utilizados, as condições de uso, as limitações conhecidas e a forma como a saída influencia uma decisão. Um sistema pode oferecer uma explicação local sem ser transparente sobre sua finalidade ou sobre os atores envolvidos. [3][13]

A OCDE relaciona transparência e explicabilidade à oferta de informações significativas e apropriadas ao contexto, inclusive para que pessoas possam compreender e contestar resultados. Transparência não é despejar documentação técnica: é tornar visível aquilo que importa para o uso responsável [13]. não é despejar documentação técnica: é tornar visível aquilo que importa para o uso responsável.

Rastreabilidade

Rastreabilidade é a capacidade de voltar no tempo e reconstruir uma execução. Isso normalmente envolve versões dos dados, modelo, explicador e política; parâmetros; resultado; intervenção humana; e registro da decisão. [3]

Sem rastreabilidade, uma organização pode explicar como o modelo costuma funcionar, mas não consegue demonstrar o que aconteceu em um caso específico.

Explicações em camadas

Uma explicação pode ser construída em camadas. Uma visão breve apresenta a decisão, os fatores principais e o canal de revisão. Uma visão de negócio mostra impacto, exceções, métricas e risco residual. Uma visão técnica detalha modelo, dados, método, parâmetros e testes. Uma visão de auditoria conecta versões, aprovações, registros e responsabilidades. [19]

Essa abordagem evita dois extremos: simplificar tanto a ponto de perder o sentido ou oferecer detalhes demais para quem precisava apenas de uma resposta clara.

DICA: A orientação do ICO e do Alan Turing Institute sobre decisões apoiadas por IA organiza diferentes tipos de explicação e mostra como contexto e público mudam a forma de comunicar [19].

3. Começar pelo problema, não pela ferramenta

A tentação tecnológica

É comum que projetos comecem com uma ferramenta disponível: “onde usar um LLM?”, “como aplicar clustering?” ou “seria possível usar SHAP neste modelo?”. Essas perguntas podem abrir possibilidades, mas não definem um problema. [3]

Uma sequência mais segura passa por cinco pontos: **problema, dado, impacto, técnica e controle**.

Problema

O problema precisa descrever a tarefa ou decisão que se deseja melhorar. “Usar IA no crédito” é amplo demais. “Estimar a probabilidade de atraso superior a 90 dias nos doze meses seguintes” já permite discutir alvo, população, dados e métricas.

Também é útil distinguir o que o sistema fará: informar, recomendar, priorizar, aprovar, bloquear ou executar. A mesma tecnologia assume riscos diferentes conforme o grau de autonomia. [3][9]

Dado

Os dados mostram uma parte do mundo. Uma varejista conhece compras realizadas em seus canais, mas não conhece automaticamente toda a situação financeira de uma pessoa. Uma plataforma educacional observa interações dentro do ambiente, mas não conhece todos os fatores que afetam o desempenho. [3]

Dizer claramente o que a base não sabe é tão importante quanto listar suas variáveis. Ausência de informação não é evidência de risco, desinteresse ou incapacidade.

Impacto

O impacto depende de quem é afetado, da gravidade do erro, da escala, da reversibilidade e da possibilidade de contestação. Uma sugestão de texto facilmente corrigida não deve receber os mesmos controles de uma decisão relacionada a crédito, emprego, saúde ou educação. [3][9]

Técnica

Abordagem	Onde costuma funcionar bem	Cuidado principal [3][20]
Regras	Condições explícitas e cálculos determinísticos	Rigidez e manutenção
ML supervisionado	Estimativas baseadas em resultados históricos	Rótulos, generalização e calibração
Clustering	Descoberta de grupos e padrões	Transformar semelhança em julgamento
LLM	Linguagem, síntese e interação	Confabulação, fontes e segurança
Sistema híbrido	Combinação de modelos, regras e pessoas	Autoridade e conflito entre componentes

Se uma regra simples resolve bem o problema, um modelo complexo pode acrescentar custo e reduzir auditabilidade sem benefício proporcional. [26]

Controle

O controle nasce do impacto. Pode envolver revisão humana, limites de autonomia, testes por subgrupo, monitoramento de deriva, proteção de dados, registro, resposta a incidentes e contestação. [3]

O EU AI Act segue uma abordagem baseada em risco e estabelece requisitos para sistemas classificados como de alto risco [9]. Mesmo fora de sua aplicação direta, a ideia de proporcionalidade continua útil.

Um registro inicial

Antes da implementação, ajuda documentar nome do caso, objetivo, horizonte, população, tipo de saída, usos permitidos e proibidos, condições de revisão e responsáveis de negócio e tecnologia. Esse registro impede que finalidade e responsabilidade permaneçam implícitas. [3][8][11]

Tecnologias como catálogos de dados, registries de modelos, plataformas de MLOps e sistemas de gestão de risco podem manter essas informações conectadas aos artefatos técnicos.

DICA: O NIST AI RMF oferece uma estrutura útil para conectar contexto, medição e tratamento de riscos ao longo do ciclo de vida [3].

4. Explicações globais e locais

Duas escalas de observação

Uma explicação global procura descrever como o modelo se comporta em geral. Ela pode mostrar quais variáveis têm maior influência, como a saída varia em diferentes faixas e em quais grupos o desempenho se deteriora. [16]

Uma explicação local se concentra em uma previsão. Ela procura responder por que determinado caso recebeu certo resultado naquele momento. [16]

Pergunta	Escopo	Caminho possível [6][7][10][16]
De quais variáveis o modelo mais depende?	Global	Permutação ou SHAP agregado
Como a saída varia com um atributo?	Global ou condicional	PDP, ICE ou ALE
Por que este caso recebeu esta estimativa?	Local	SHAP, LIME ou regra
O que poderia alterar o resultado?	Local e acionável	Contrafactual

Por que as duas são necessárias

Um comportamento médio aceitável pode esconder decisões locais incoerentes. Da mesma forma, alguns casos individuais plausíveis não garantem que o modelo se comporte bem no conjunto.

Considere um modelo de crédito. Globalmente, atrasos recentes e comprometimento de renda podem aparecer como fatores relevantes. Localmente, um pedido pode ter sido influenciado também pelo valor solicitado, por dados ausentes ou por uma combinação pouco comum. A explicação local detalha o caso; a global ajuda a verificar se ele faz parte de um padrão.

Explicação não é causa

Métodos de XAI normalmente descrevem o comportamento do modelo. Se SHAP indica que um atributo elevou a previsão, isso significa que o modelo utilizou aquela informação de determinada forma. Não significa que o atributo causou o evento no mundo real. [6][16]

Essa diferença é central. Modelos aprendem associações presentes nos dados. Causalidade exige hipóteses, desenho de estudo e evidências adicionais. [16]

Uma leitura combinada

Uma investigação consistente reúne comportamento global, casos locais típicos e extremos, conhecimento do domínio, qualidade dos dados, métricas por grupos e regras de negócio. XAI ganha força quando faz parte desse conjunto. Isolada, pode transformar um padrão matemático em uma narrativa mais confiante do que a evidência permite. [16][18]

Bibliotecas como SHAP, LIME, InterpretML, Alibi Explain e ferramentas de inspeção do scikit-learn oferecem recursos para diferentes escalas. A escolha deve partir da pergunta, não da popularidade da biblioteca.

DICA: O livro aberto *Interpretable Machine Learning*, de Christoph Molnar, apresenta métodos globais e locais com exemplos, vantagens e limitações [16].

5. Quando o próprio modelo já é uma explicação

Simplicidade como escolha de projeto

Em algumas situações, o caminho mais consistente para a explicabilidade é escolher um modelo cujo mecanismo possa ser compreendido diretamente. Regressões com um conjunto controlado de variáveis, árvores curtas, listas de regras e modelos aditivos são exemplos comuns. [16][26]

A vantagem não está apenas na facilidade de desenhar o modelo em uma página. Modelos interpretáveis permitem discutir relações, testar premissas e localizar comportamentos inesperados sem depender inteiramente de uma técnica posterior de explicação. [26]

Interpretável não significa infalível

Uma regra clara pode formalizar uma decisão injusta. Uma regressão pode refletir vieses históricos. Uma árvore pode parecer intuitiva e, ainda assim, ser instável diante de pequenas mudanças na amostra. [16][26]

Interpretabilidade é uma condição favorável à inspeção, não um certificado de qualidade.

Modelo	O que facilita	Onde exige cuidado
Regressão linear ou logística	Leitura de sinais e magnitudes	Escala, correlação e interações
Árvore curta	Visualização das divisões	Instabilidade e simplificação excessiva
Lista de regras	Comunicação direta	Crescimento e conflito entre regras
Modelo aditivo	Relações não lineares por atributo	Interações e leitura condicionada

Um baseline que vale a pena

Antes de adotar um modelo complexo, um baseline interpretável oferece uma referência. Ele ajuda a responder quanto desempenho adicional está sendo obtido em troca de maior complexidade. [26]

Scikit-learn, statsmodels, InterpretML e bibliotecas de árvores possuem recursos para criar esses baselines. A comparação não precisa ficar restrita à acurácia. Calibração, estabilidade, custo de operação, facilidade de auditoria e impacto dos erros também fazem parte da escolha.

A leitura dos coeficientes

Na regressão logística, um coeficiente positivo indica aumento no logaritmo das chances quando o atributo cresce, mantidas as demais variáveis do modelo. Isso não equivale a relação causal. A interpretação depende da unidade, padronização, codificação e presença de interações. [16]

Um coeficiente associado à “renda padronizada” é menos útil para comunicação do que uma tradução para a unidade original. O processo precisa preservar essa ponte entre a representação matemática e o vocabulário do negócio.

A leitura das árvores

Árvores curtas parecem naturais porque reproduzem uma sequência de perguntas. Ainda assim, é importante observar quantos casos chegam a cada folha, a taxa de erro, a estabilidade das divisões e o que acontece nas fronteiras. [16]

Uma divisão em “idade menor que 37,5” não significa que exista uma mudança real e súbita aos 38 anos. O ponto foi escolhido pelo algoritmo para aquela amostra e aquele objetivo.

DICA: Modelos interpretáveis são especialmente interessantes quando a diferença de desempenho em relação a alternativas complexas é pequena. A escolha passa a ser uma decisão de engenharia, risco e custo, não apenas de métrica. [26]

6. Importância e efeito das variáveis

Duas perguntas diferentes

Saber que uma variável é importante não mostra automaticamente como ela afeta a previsão. Vale separar duas perguntas: [5][16]

- **Importância:** quanto o modelo depende dessa variável?
- **Efeito:** como a saída muda quando a variável assume valores diferentes?

Essa distinção evita leituras apressadas de rankings.

Importância por permutação

A importância por permutação embaralha os valores de uma variável e mede quanto o desempenho piora. Se a queda for grande, o modelo dependia bastante daquela informação no conjunto avaliado. A documentação do scikit-learn reforça que o resultado está ligado ao modelo, à amostra e à métrica escolhida [5].

Scikit-learn, MLflow, plataformas de MLOps e serviços gerenciados de nuvem podem apoiar esse tipo de análise e seu registro.

Uma variável pode parecer pouco importante porque outra variável correlacionada preserva informação semelhante. Também é possível que um modelo ruim apresente um ranking organizado. Convém avaliar o desempenho antes de interpretar a importância. [5][16]

PDP, ICE e ALE

O **Partial Dependence Plot (PDP)** mostra como a previsão média varia quando um atributo é alterado. A curva **ICE** mantém uma linha por observação, revelando diferenças que a média pode esconder. O **Accumulated Local Effects (ALE)** trabalha com efeitos locais acumulados e pode reduzir alguns problemas de extrapolação quando há correlação entre atributos. [16]

Ferramentas de inspeção do scikit-learn, PyALE, Alibi Explain e InterpretML ajudam a produzir essas análises. O cuidado mais conhecido do PDP está nas combinações irreais: variar uma característica sem respeitar sua relação com as demais pode criar perfis que não existem. [16]

O que um bom gráfico precisa mostrar

Além da curva, é útil apresentar onde estão os dados. Uma tendência em uma faixa com poucas observações tem significado diferente de uma tendência sustentada por muitos casos. Intervalos, dispersão e frequência ajudam a evitar que regiões frágeis pareçam conclusivas.

Também vale procurar interações. O valor solicitado pode ter efeito discreto quando o comprometimento é baixo e efeito muito maior quando o comprometimento já está elevado. A média isolada pode suavizar essa diferença.

Uma leitura cuidadosa

Esses métodos observam o comportamento do modelo. Eles não demonstram que uma variável causa o resultado e não atribuem valor moral às pessoas representadas. A linguagem mais adequada costuma ser “o modelo depende”, “a previsão varia” ou “o atributo contribui”, em vez de “a variável determina”. [16]

DICA: A documentação de inspeção de modelos do scikit-learn oferece exemplos reproduzíveis de importância por permutação e dependência parcial [5].

7. SHAP: contribuições por atributo

A ideia central

SHAP, sigla de *SHapley Additive exPlanations*, distribui entre os atributos a diferença entre a saída observada e um valor de referência. O método se inspira nos valores de Shapley, usados para distribuir de maneira consistente o resultado de uma cooperação entre participantes. Lundberg e Lee reuniram diferentes métodos de explicação aditiva nessa estrutura [6].

Em termos conceituais, parte-se de um valor de referência e somam-se contribuições atribuídas às variáveis até chegar à saída do modelo. Essa decomposição pode ser local, para uma previsão, ou agregada, para observar padrões no conjunto. [6]

O valor de referência

A referência não é um detalhe neutro. Ela define o ponto a partir do qual as contribuições serão descritas. Uma pessoa pode parecer de alto risco em relação à população geral e de baixo risco em relação a um grupo específico. O modelo é o mesmo; a narrativa muda porque a comparação mudou. [6][15]

O conjunto de fundo precisa ser representativo, justificado e versionado. Escolher uma referência conveniente depois de observar o resultado enfraquece a explicação. [6][15]

Explicações locais e visão global

Um gráfico *waterfall* mostra como os atributos conduziram uma previsão desde o valor base até o resultado. Um *beeswarm* reúne observações e permite ver magnitude, direção e dispersão das contribuições. Gráficos de dependência ajudam a investigar relações e possíveis interações. [6][15]

A biblioteca SHAP oferece explicadores para árvores, modelos lineares, redes neurais e modelos genéricos. Serviços como SageMaker Clarify e componentes de Responsible AI em plataformas de nuvem podem incorporar análises semelhantes em fluxos de MLOps.

Escala e sinal

Em classificação, a explicação pode estar em probabilidade, log-odds ou saída bruta. Um valor positivo não significa automaticamente “bom” ou “ruim”; significa movimento na direção da saída explicada. Antes de apresentar um gráfico, é necessário declarar a classe e a escala. [6][15]

Correlação e divisão de crédito

Quando atributos carregam informação semelhante, não existe uma única forma óbvia de dividir a contribuição entre eles. Renda, limite e comprometimento podem estar relacionados. Dependendo do método e da maneira como a dependência é tratada, a atribuição muda. [6][16]

Valores SHAP descrevem o modelo. Não são características intrínsecas de uma pessoa e não demonstram causalidade. [6]

Onde SHAP pode enganar

Uma explicação matematicamente correta pode conduzir a uma interpretação ruim se o modelo tiver aprendido um padrão inadequado. Pesquisas também mostraram que explicadores posteriores ao treinamento podem ser atacados para apresentar razões benignas enquanto o comportamento subjacente permanece problemático [18].

Isso não torna SHAP inútil. Mostra que ele precisa fazer parte de uma investigação maior, com testes, dados, métricas e revisão de domínio.

DICA: A documentação oficial do SHAP reúne orientações para dados tabulares, texto e imagem e esclarece diferenças entre explicadores e escalas [15].

8. LIME: uma aproximação ao redor da previsão

Uma explicação local

LIME significa *Local Interpretable Model-Agnostic Explanations*. Sua proposta é observar o comportamento de um modelo complexo ao redor de uma previsão e ajustar, naquela vizinhança, um modelo mais simples e interpretável. O trabalho original apresentou a técnica como uma forma de explicar classificadores de diferentes tipos [7].

A palavra mais importante é **local**. A explicação não descreve o modelo inteiro. Ela descreve uma aproximação em torno de um ponto. [7]

Como funciona

De maneira resumida, LIME cria variações próximas da observação, consulta o modelo original, atribui pesos conforme a proximidade e ajusta um modelo interpretável. O resultado destaca os atributos mais relevantes naquela aproximação. [7]

As bibliotecas LIME, Alibi Explain e ferramentas integradas em plataformas de ciência de dados podem apoiar esse processo.

A vizinhança importa

Se as perturbações criarem casos impossíveis, o modelo substituto aprenderá a partir de uma região artificial. Idade negativa, categorias inexistentes ou combinações incompatíveis reduzem a utilidade da explicação. [7]

A largura da vizinhança também influencia o resultado. Muito estreita pode capturar ruído; muito ampla pode deixar de representar o comportamento local. [7]

Estabilidade

LIME utiliza amostragem e pode variar entre execuções. Repetir a explicação com sementes e configurações diferentes ajuda a perceber se a narrativa é estável. Quando pequenas mudanças produzem fatores completamente diferentes, a explicação precisa ser tratada com cautela. [7]

Uma boa leitura combina fidelidade do modelo local, repetição, comparação com outro método, plausibilidade das perturbações e conhecimento do domínio.

SHAP ou LIME?

Não existe resposta universal. SHAP oferece propriedades aditivas e uma família ampla de explicadores. LIME é flexível, intuitivo e útil para observar uma aproximação local. Ambos dependem de escolhas e podem ser mal interpretados.

O melhor método é aquele que responde à pergunta certa com fidelidade e estabilidade suficientes para o risco do uso. [6][7]

DICA: O artigo original de Ribeiro, Singh e Guestrin apresenta a motivação de LIME e exemplos em texto e imagem [7].

9. Contrafactuais: o que precisaria mudar

Da explicação à ação

Enquanto SHAP e LIME mostram fatores associados a uma previsão, uma explicação contrafactual procura responder: **o que precisaria ser diferente para que o resultado mudasse?** [10]

A ideia ganhou destaque por oferecer uma explicação próxima da ação e da contestação, sem exigir que toda a lógica interna do modelo seja aberta [10].

Nem toda mudança é útil

“Se a idade fosse menor” pode alterar uma previsão, mas não oferece ação possível. “Se o dado de renda estiver incorreto, a atualização documental permite nova análise” é diferente: existe um caminho concreto. [10]

Contrafactuais úteis combinam validade, proximidade, plausibilidade, possibilidade de ação, coerência entre variáveis, diversidade de alternativas e justiça.

Restrições fazem parte da explicação

Um gerador de contrafactuais precisa conhecer o domínio. Alguns atributos são imutáveis. Outros só aumentam com o tempo. Há limites, categorias permitidas e relações que não podem ser quebradas. [10]

Tecnologias como DiCE, Alibi Explain e CARLA apoiam a criação e a avaliação de contrafactuais. Ainda assim, regras do domínio e critérios de ação precisam ser definidos fora da ferramenta.

Sem essas restrições, o sistema pode recomendar uma situação matematicamente conveniente e humanamente absurda.

Correção, mudança e garantia

Uma comunicação contrafactual precisa distinguir três situações: correção de dado, mudança de condição e mudança de política. Também deve evitar promessas. Mesmo que uma condição mude, modelo, dados e política podem ser atualizados. O mais correto é falar em possibilidade de reavaliação, não em garantia de resultado. [10]

Um exemplo

Em vez de apenas informar que um pedido de R\$ 50 mil foi recusado, a comunicação poderia indicar que comprometimento elevado e atraso recente foram fatores relevantes e que uma nova análise pode ser feita com dados atualizados, valor menor ou após um período sem novos atrasos — desde que essas condições sejam legítimas, viáveis e previstas na política.

DICA: O trabalho de Wachter, Mittelstadt e Russell discute contrafactuais como apoio à compreensão, à contestação e à identificação de mudanças relevantes [10].

10. Explicabilidade em redes neurais e IA generativa

Imagens e sinais

Em redes neurais, mapas de saliência procuram destacar regiões da entrada associadas à saída. Gradientes integrados, Grad-CAM, oclusão e métodos de perturbação são caminhos comuns. Em uma imagem médica, por exemplo, o mapa pode indicar quais regiões mais influenciaram uma classificação. [17]

Ferramentas como Captum, tf-explain, SHAP e bibliotecas específicas de visão ajudam a produzir essas análises. O resultado visual costuma ser atraente, mas aparência não é validação. Testes de sanidade demonstraram que alguns métodos podem produzir mapas semelhantes mesmo após mudanças importantes no modelo ou nos dados [17].

Atenção não é explicação automática

Mecanismos de atenção ajudam modelos a ponderar informações durante o processamento. Seus pesos podem oferecer pistas, mas não devem ser tratados automaticamente como causa ou justificativa completa. A utilidade explicativa depende da arquitetura e da pergunta investigada. [27]

O caso dos LLMs

Com grandes modelos de linguagem, a palavra “explicação” pode esconder objetos diferentes:

- **Proveniência:** de onde veio a informação apresentada? [20]
- **Grounding:** a resposta é sustentada pelos documentos fornecidos?
- **Comportamento:** quais instruções, ferramentas e dados influenciaram a execução?
- **Decisão:** como o texto produzido se transformou em ação?

Pedir ao modelo que “explique o próprio raciocínio” não garante descrição fiel do processo interno. O modelo pode produzir uma justificativa coerente depois da resposta. Em ambientes corporativos, evidências verificáveis são mais úteis: documentos consultados, trechos citados, chamadas de ferramentas, cálculos determinísticos, regras aplicadas e versões. [29]

RAG e fontes

Retrieval-Augmented Generation combina recuperação de documentos com geração de texto. Tecnologias como Vertex AI, Azure AI Foundry, Amazon Bedrock, LangChain, LlamaIndex e bancos vetoriais ajudam a criar esse fluxo. A recuperação pode tornar a resposta mais atual e conectada a fontes corporativas, mas não elimina erros. [28]

Uma avaliação consistente separa dois componentes: a busca encontrou documentos corretos e suficientes? A resposta permaneceu fiel ao conteúdo recuperado? Ferramentas como RAGAS, TruLens, DeepEval e LangSmith podem apoiar testes e observabilidade, mas métricas automáticas não substituem avaliação humana e conhecimento do domínio. [20][28]

Também é importante verificar autorização. Um bom mecanismo de busca não deve recuperar documentos aos quais a pessoa não teria acesso fora do sistema. [3][20]

Uma arquitetura possível

Uma aplicação pode combinar autenticação, identificação da intenção, recuperação com controle de acesso, geração com contexto, verificação de fontes, ferramentas determinísticas, revisão quando necessária e registro. Cada componente possui uma responsabilidade clara. [3][20]

Cálculos exatos, consultas e ações devem ser encaminhados a componentes apropriados. O LLM pode orquestrar ou explicar, mas não precisa inventar o resultado de uma operação que um serviço determinístico consegue executar.

Prompt injection

Prompt injection ocorre quando uma entrada altera o comportamento do sistema de modo não pretendido. A instrução pode vir diretamente do usuário ou estar escondida em um documento recuperado. O OWASP inclui esse risco entre os principais desafios de aplicações com LLM e recomenda controles como privilégio mínimo, separação de conteúdo não confiável, validação e confirmação humana para ações sensíveis [21].

RAG e ajuste fino não eliminam prompt injection. A segurança precisa existir na arquitetura, nas permissões, nas ferramentas e na monitoração. [20][21]

Evidências úteis

Em sistemas generativos, rastrear apenas o texto final é pouco. O registro pode incluir versão do modelo, instrução de sistema, parâmetros, fontes recuperadas, permissões, ferramentas acionadas, filtros, resposta e intervenções. [20]

Plataformas de observabilidade como OpenTelemetry, MLflow, Langfuse, Arize Phoenix e soluções nativas de nuvem podem apoiar essa rastreabilidade. O perfil de IA generativa do NIST trata riscos de confabulação, integridade da informação, segurança e privacidade e recomenda verificação de fontes, monitoramento e testes adversariais [20].

DICA: A combinação entre NIST AI 600-1 e OWASP Top 10 para aplicações com LLM oferece uma ponte entre gestão de risco e segurança técnica [20][21].

11. Como saber se uma explicação é boa

Uma qualidade com várias dimensões

Não existe uma única métrica capaz de declarar que uma explicação é boa. Uma explicação pode ser fiel ao modelo e incompreensível. Pode ser clara e tecnicamente incorreta. Pode funcionar em um caso e mudar completamente diante de uma variação mínima. [2][16]

Dimensão	Pergunta [2][16]
Fidelidade	A explicação representa o comportamento do modelo?
Estabilidade	Casos semelhantes recebem explicações semelhantes?
Robustez	A explicação resiste a ruído e manipulação?
Completude	As contribuições recompõem a saída na escala declarada?
Compreensão	A mensagem é entendida como se pretendia?
Utilidade	Ela ajuda a investigar, decidir ou contestar?
Ação	As alternativas são viáveis?
Justiça	A qualidade se mantém entre grupos relevantes?

Fidelidade

Uma explicação fiel acompanha o modelo explicado. Em modelos substitutos locais, é possível medir a concordância entre o substituto e o modelo original na vizinhança. Em métodos aditivos, pode-se verificar se as contribuições recompõem a saída. [2][7]

Fidelidade ao modelo não é fidelidade à realidade. Se o modelo estiver errado, uma explicação fiel mostrará com precisão um comportamento errado. [2]

Estabilidade

Pequenas variações que não alteram significativamente a previsão não deveriam produzir narrativas completamente diferentes. Repetições com sementes, fundos e amostras alternativas ajudam a revelar fragilidade. [7][16]

Bibliotecas como Quantus, Xplique e Captum oferecem métricas e recursos de avaliação para diferentes modalidades. O nível esperado de estabilidade depende do uso: uma ferramenta exploratória pode tolerar variação maior do que uma justificativa oficial.

Compreensão e utilidade

Uma explicação só é significativa se for compreendida de maneira compatível com sua intenção. Isso pode ser avaliado com pessoas que representem o público real, observando interpretação, tempo, erros e decisões tomadas a partir da mensagem. [2][19]

O NIST destaca que uma explicação deve ser significativa para seu destinatário e refletir corretamente o processo do sistema. Clareza sem fidelidade vira persuasão; fidelidade sem compreensão vira documentação inacessível [2]. sem fidelidade vira persuasão; fidelidade sem compreensão vira documentação inacessível.

Casos que merecem atenção

A avaliação não deve se limitar a previsões corretas e comuns. Casos limítrofes, extremos, fora de distribuição, falsos positivos, falsos negativos e decisões contestadas são especialmente informativos. [2][3]

Mudanças no modelo também podem alterar explicações sem alterar a métrica média. Testes de regressão de explicabilidade ajudam a perceber quando uma nova versão passa a depender de sinais diferentes. [3]

DICA: Uma forma útil de aprofundar o tema é comparar a mesma previsão usando métodos e conjuntos de referência diferentes, documentando o que permanece estável e o que muda.

12. Viés, justiça, privacidade e segurança

XAI investiga, não absolve

Uma explicação pode revelar que o modelo depende de uma variável problemática. Isso é valioso, mas não corrige automaticamente o problema. Da mesma forma, um gráfico visualmente equilibrado não demonstra que o sistema é justo. [3][14]

Viés pode surgir na escolha do problema, coleta de dados, rótulos, amostragem, modelagem, limiares, interface e operação. A explicabilidade observa parte desse caminho; a governança precisa observar o conjunto. [3][14]

Proxies

Remover uma característica sensível não impede que outras variáveis carreguem informação semelhante. CEP, escola, padrão de consumo ou histórico de navegação podem funcionar como proxies, dependendo do contexto. [14]

Quando um proxy aparece como importante, a investigação precisa considerar sua função, necessidade, impacto e alternativas. Retirá-lo sem medir o efeito também pode piorar o modelo ou deslocar o problema para outra variável.

Justiça não é uma única métrica

Taxas de erro, calibração e seleção podem ser comparadas entre grupos, mas diferentes critérios de justiça podem entrar em tensão. A escolha precisa partir do dano, da decisão e do contexto jurídico e social. [30]

Fairlearn, AI Fairness 360 e Responsible AI Dashboard são tecnologias que ajudam a calcular e comparar métricas de equidade. Elas apoiam o diagnóstico; não decidem qual concepção de justiça é apropriada.

Não existe botão de “remover viés”. Existe um processo de definição, medição, negociação de trade-offs, mitigação e acompanhamento. [30]

Privacidade das explicações

Explicações também podem vaziar informação. Um serviço muito detalhado pode facilitar inferências sobre dados de treinamento, atributos de terceiros, regras antifraude ou segredos comerciais. [3][14]

Transparência não significa exposição ilimitada. Minimização, agregação, controle de acesso, privacidade diferencial e separação entre comunicação externa e investigação interna podem ajudar. Tecnologias como OpenDP, TensorFlow Privacy e serviços de gestão de identidades apoiam partes desse desenho.

Segurança

Modelos e explicadores podem ser alvos de manipulação, extração e evasão. Aplicações generativas acrescentam prompt injection, vazamento de contexto e uso indevido de ferramentas. [18][20][21]

Proteção de registros, assinatura de artefatos, controle de versões, testes adversariais e privilégio mínimo preservam a integridade das evidências. Serviços de IAM, cofres de segredos, SIEM, scanners de segurança e ferramentas de red teaming podem ser combinados a essa estratégia. [3][20][21]

Uma postura equilibrada

XAI é mais útil como instrumento de investigação. Ela ajuda a perguntar se o modelo usa sinais plausíveis, depende de proxies, concentra erros, expõe informação indevida, pode ser manipulado ou induz confiança excessiva. [3][14]

DICA: A recomendação da UNESCO sobre ética em IA conecta transparência e explicabilidade a direitos, supervisão, privacidade e possibilidade de revisão [14].

13. Supervisão humana e contestação

Mais do que um botão

A presença de uma pessoa no processo não garante supervisão efetiva. Se há milhares de alertas por hora, pouca informação, tempo insuficiente ou punição para quem discorda do sistema, a revisão vira formalidade. [9][31]

Uma supervisão real depende de competência, contexto, autoridade e condições de trabalho. [9][31]

Três formas de participação

Forma	Como a pessoa participa
Human-in-the-loop	Revisa cada ação ou casos definidos
Human-on-the-loop	Acompanha o processo e intervém quando necessário
Human-in-command	Define objetivos, limites e autoridade de suspensão

Esses termos ajudam a descrever arranjos, mas o desenho concreto é mais importante que o rótulo.

Viés de automação

Quando um sistema apresenta uma recomendação com aparência precisa, é comum que ela se torne uma âncora. Interfaces podem agravar esse efeito: concordar exige um clique, enquanto discordar exige preencher vários campos. [31]

Algumas situações pedem avaliação humana inicial antes da exibição do score. Em outras, mostrar incerteza, evidência e alternativas pode reduzir a aceitação automática. [9][31]

Exceções e abstenção

Nem todo caso precisa seguir o mesmo caminho. Uma arquitetura pode automatizar situações de baixo risco, encaminhar uma faixa intermediária e interromper decisões quando há dados conflitantes ou fora das condições conhecidas. [2][3]

Mecanismos de workflow, motores de regras e ferramentas de gestão de casos podem controlar alçadas, exceções, prazos e escalonamentos. Abster-se não é necessariamente falha. Em alguns contextos, é sinal de que o sistema reconhece limites [2].

Contestação

Uma explicação se torna mais relevante quando existe possibilidade de agir sobre ela. Isso pode envolver corrigir dados, apresentar documentação, solicitar revisão ou compreender o fundamento de uma decisão. [4][9]

O canal precisa ser acessível, tempestivo e conectado a alguém com autoridade. Plataformas de atendimento, gestão de casos e workflow ajudam a registrar a solicitação e seu desfecho. Reversões procedentes podem revelar erro de dado, modelo, política, interface ou procedimento. [4][9]

O papel da organização

A supervisão não transfere toda a responsabilidade para quem está na ponta. A organização continua responsável por volume, treinamento, critérios, interface, incentivo e qualidade das evidências. “Havia um humano no processo” não é defesa suficiente quando o desenho não permitia revisão efetiva. [3][9]

DICA: O EU AI Act descreve requisitos de supervisão humana para sistemas de alto risco, incluindo compreensão de capacidades e limitações, prevenção de dependência excessiva e possibilidade de ignorar ou interromper a saída [9].

14. Governança contínua de IA

A explicabilidade ao longo do ciclo

Governança de IA não é uma aprovação realizada na véspera da implantação. Ela começa quando o caso é proposto e continua até a retirada do sistema. [3][12]

O NIST AI RMF organiza esse trabalho em quatro funções: Governar, Mapear, Medir e Gerenciar. Elas funcionam como ciclo: Governar cria políticas e responsabilidades; Mapear esclarece contexto e impactos; Medir reúne testes e evidências; Gerenciar prioriza riscos e aplica controles [3]. funcionam como ciclo: Governar cria políticas e responsabilidades; Mapear esclarece contexto e impactos; Medir reúne testes e evidências; Gerenciar prioriza riscos e aplica controles.

Um inventário que faça sentido

Antes de governar, é necessário saber quais sistemas existem. Um inventário pode registrar nome, proprietário, finalidade, técnica, fornecedor, dados, público, impacto, status, jurisdições, dependências, versões e controles. [3]

Catálogos corporativos, plataformas de GRC, registries de modelos, CMDBs e soluções específicas de governança de IA podem apoiar esse inventário. Uma estrutura simples e bem mantida é mais útil que uma ferramenta avançada sem participação das áreas.

Documentos vivos

Model Cards foram propostas para documentar finalidade, contexto, desempenho, grupos avaliados e limitações [8]. *Datasheets for Datasets* organizam motivação, composição, coleta, processamento e usos recomendados dos dados [11]. [8][11]

MLflow, Vertex AI Model Registry, SageMaker Model Registry, Azure Machine Learning e catálogos de dados podem manter essas informações conectadas às versões. O valor dos documentos depende dessa ligação com a operação.

Portões de decisão

Momento	Pergunta principal [3][12]
Ideia	O problema justifica IA?
Dados	As informações são adequadas e permitidas?
Modelo	O desempenho e as explicações são suficientes?
Implantação	Existem segurança, supervisão, registros e retorno de versão?
Operação	O sistema continua dentro dos limites?
Retirada	Dependências, registros e comunicação foram tratados?

Monitoramento além da acurácia

A operação pode acompanhar qualidade e deriva dos dados, desempenho, calibração, distribuição das previsões, atribuições, falhas, intervenções, incidentes e contestações. [3]

Evidently AI, WhyLabs, Arize, Fiddler, MLflow e serviços gerenciados de nuvem oferecem recursos de monitoramento e observabilidade. Mudanças nas explicações podem sinalizar que o modelo passou a depender de padrões diferentes, mesmo quando uma métrica média permanece estável.

Papéis claros

Negócio, tecnologia, dados, risco, jurídico, privacidade, segurança, compliance e auditoria observam aspectos diferentes. Uma matriz RACI ajuda, desde que represente a autoridade real. [3][12]

Governança existe quando é possível demonstrar o que foi decidido, por quem, com base em quais evidências e por quanto tempo aquela decisão permanece válida. [3]

DICA: A ISO/IEC 42001 estrutura requisitos para estabelecer, manter e melhorar continuamente um sistema de gestão de IA. Ela pode ser combinada ao NIST AI RMF para conectar gestão organizacional e tratamento de riscos [12]. pode ser combinada ao NIST AI RMF para conectar gestão organizacional e tratamento de riscos.

15. Leis, normas e prestação de contas

LGPD e decisões automatizadas

No Brasil, o artigo 20 da Lei Geral de Proteção de Dados prevê o direito de solicitar revisão de decisões tomadas unicamente com base em tratamento automatizado de dados pessoais que afetem interesses. O texto também trata do fornecimento de informações claras e adequadas sobre critérios e procedimentos, observados os segredos comercial e industrial [4].

Isso não se resume a revelar código-fonte. Pede capacidade de identificar as decisões alcançadas, localizar evidências, explicar critérios de forma útil, corrigir dados e encaminhar uma revisão. [4]

EU AI Act

O Regulamento Europeu de IA utiliza uma abordagem baseada em risco. Sistemas de alto risco ficam sujeitos a requisitos relacionados a gestão de risco, dados, documentação, registros, transparência, supervisão humana, acurácia, robustez e cibersegurança [9].

A aplicação depende do papel da organização, do uso e da jurisdição. Uma empresa pode ser provedora, implantadora, importadora ou distribuidora, e as obrigações não são idênticas. [9]

ISO/IEC 42001

A ISO/IEC 42001 estabelece requisitos para um sistema de gestão de IA. Seu foco está na forma como a organização estrutura políticas, objetivos, responsabilidades, avaliação, operação e melhoria contínua [12]. O foco está na forma como a organização estrutura políticas, objetivos, responsabilidades, avaliação, operação e melhoria contínua.

Uma certificação de sistema de gestão não significa que toda resposta de IA esteja correta. Ela demonstra que existe uma estrutura para administrar o tema conforme o escopo avaliado. [12]

Princípios e frameworks

OCDE e UNESCO oferecem princípios relacionados a direitos humanos, transparência, explicabilidade, robustez, supervisão e accountability [13][14]. O NIST AI RMF traduz várias dessas preocupações em funções de gestão de risco [3].

Esses instrumentos não precisam gerar programas paralelos. Uma organização pode construir um sistema integrado de controles e mapear como cada evidência atende diferentes requisitos.

Da obrigação à evidência

[3][4][9][12]

A lei ou norma estabelece uma expectativa; a política interna a traduz; o processo define como será cumprida; o sistema registra a execução; e a auditoria verifica se o controle funciona. [3][4][9][12]

Plataformas de GRC, gestão documental, workflow e trilhas de auditoria podem conectar essas camadas. Explicabilidade aparece em todas elas ao ligar a saída técnica à capacidade de prestar contas.

Cuidado com interpretações genéricas

Termos como “direito à explicação”, “alto risco” e “decisão automatizada” dependem do instrumento e do caso. Materiais educacionais ajudam a reconhecer questões, mas não substituem avaliação jurídica especializada.

DICA: A leitura direta da LGPD, do EU AI Act e da página oficial da ISO evita simplificações encontradas em resumos comerciais [4][9][12].

16. XAI como capacidade corporativa

Muito além de um gráfico

Quando XAI é tratada apenas como biblioteca, cada projeto cria suas próprias definições, escalas e formas de comunicação. O resultado costuma ser uma coleção de gráficos sem padrão comum. [3][12]

Uma capacidade corporativa de explicabilidade combina cinco elementos:

6. **Portfólio:** inventário e classificação dos sistemas.
7. **Padrões:** conceitos, métodos, documentos e critérios.
8. **Plataforma:** componentes reutilizáveis e observabilidade.
9. **Pessoas:** papéis, competências e comunidades de prática.
10. **Garantia:** validação, auditoria, incidentes e contestação.

Onde está o valor

XAI pode reduzir o tempo de investigação, melhorar atendimento, revelar dependências problemáticas, facilitar validação e tornar decisões mais defensáveis. Também pode mostrar que um modelo não deveria ser implantado. [3][19]

Seu valor não está em fazer todos confiarem na IA. Está em permitir confiança calibrada: suficiente quando há evidência, reduzida quando existem dúvidas e suspensão quando o sistema ultrapassa seus limites. [2][3]

Um caminho de adoção

O primeiro movimento é descobrir sistemas, decisões, responsáveis e impactos. Depois vêm padrões comuns de vocabulário, classificação, documentação, explicação e revisão. Na sequência, testes, registros, monitoramento e aprovações podem ser integrados ao ciclo de desenvolvimento. Por fim, a capacidade é ampliada a fornecedores, áreas e geografias e aprende continuamente com incidentes, contestações e auditorias. [3][12]

Indicadores que ajudam

Dimensão	Exemplo de indicador
Visibilidade	Sistemas inventariados e classificados
Evidência	Documentação e validação vigentes
Operação	Tempo para reconstruir uma decisão
Explicação	Cobertura, fidelidade e estabilidade
Contestação	Prazo, reversões e causas
Modelo	Calibração, deriva e desempenho por grupo
Valor	Retrabalho, tempo de análise e impacto financeiro

Contar quantas Model Cards foram preenchidas diz pouco se ninguém consegue reconstruir uma decisão ou interromper um sistema problemático.

Um modelo operacional conectado

Governança de IA funciona melhor quando se conecta a gestão de produto, arquitetura, dados, segurança, privacidade, compliance, risco, auditoria e continuidade. [3][12]

Plataformas como MLflow, Kubeflow, Vertex AI, Azure Machine Learning, SageMaker, catálogos de dados e soluções de GRC podem compor o ecossistema. A tecnologia escolhida deve se ajustar ao modelo operacional; não deve defini-lo sozinha.

Criar um comitê sem autoridade ou um processo paralelo tende a aumentar burocracia. Integrar decisões e evidências aos fóruns que já controlam orçamento, risco e implantação costuma produzir resultados mais concretos. [3][12]

DICA: O NIST AI RMF Playbook apresenta sugestões de ações para transformar as funções Governar, Mapear, Medir e Gerenciar em práticas organizacionais [3].

17. Caso integrado: ACME Co.

O contexto

A ACME Co. é uma varejista omnicanal fictícia. Ela possui lojas físicas, aplicativo e parcelamento próprio. A empresa deseja ampliar a oferta de crédito e acredita que seus dados de compra podem ajudar.

Logo no início aparecem três problemas diferentes:

Pergunta	Abordagem possível	Resultado legítimo
Que padrões de compra existem?	Clustering	Segmentos para formular hipóteses
Qual é a chance de atraso?	Modelo supervisionado	Probabilidade validada e calibrada
Qual limite deve ser concedido?	Política, regras e supervisão	Decisão registrada e governada

Misturar essas perguntas criaria atalhos perigosos. Um segmento de baixa frequência não representa automaticamente alto risco de crédito.

O que a base mostra

A ACME conhece frequência de compra, ticket médio, canal, tempo de relacionamento e pontualidade em parcelamentos internos. Ela não conhece automaticamente renda atual, exposição em outras instituições, acontecimentos recentes ou o motivo de uma pessoa comprar pouco.

Essa diferença é registrada antes da modelagem. A equipe evita transformar lacunas em julgamentos.

O modelo

O alvo é atraso superior a 90 dias em doze meses. A separação de treino e teste respeita o tempo, reduzindo o risco de usar informações futuras. Além de discriminação, são avaliadas calibração, taxas de erro e desempenho em grupos relevantes.

Uma regressão logística serve de baseline. Um modelo de árvores apresenta ganho relevante, mas exige explicações adicionais. Scikit-learn, XGBoost ou LightGBM podem apoiar a modelagem; MLflow ou registries gerenciados podem acompanhar versões e métricas. A escolha final considera ganho, estabilidade, custo e capacidade de auditoria.

A explicação global

Importância por permutação e SHAP agregado mostram forte dependência de comprometimento, atrasos recentes e valor solicitado. PDP e ICE sugerem interação entre comprometimento e valor. Scikit-learn, SHAP, InterpretML ou soluções de Responsible AI podem apoiar essas análises.

CEP também aparece. Em vez de aceitar ou remover imediatamente, a equipe investiga proxies, impacto por grupos e desempenho com alternativas. A decisão é documentada.

A explicação local

Um pedido de R\$ 50 mil recebe estimativa acima do limiar de revisão. SHAP indica contribuições positivas de comprometimento elevado, atraso recente e valor solicitado; renda comprovada e relacionamento longo reduzem a estimativa.

A comunicação evita dizer que esses fatores “causaram” o risco. Ela informa que contribuíram para a estimativa, apresenta os dados utilizados e oferece possibilidade de correção.

O contrafactual

A política permite nova análise com valor menor e dados atualizados. Tecnologias como DiCE ou Alibi Explain podem apoiar a geração de alternativas, desde que as restrições venham do domínio. O sistema apresenta uma alternativa plausível, sem prometer aprovação. Idade e outros atributos imutáveis não entram como recomendação.

A decisão

O modelo estima. A política define faixas e condições. Casos intermediários ou fora de distribuição seguem para revisão. A pessoa responsável pode discordar, solicitar documentação ou interromper o processo.

Cada execução registra versões dos dados, modelo e política; método de explicação e referência; resultado; motivo estruturado; intervenção; horário e identificador. Um registry, uma plataforma de MLOps e um mecanismo de workflow podem sustentar essa trilha.

O assistente generativo

Um LLM ajuda a resumir documentos e redigir a comunicação. Ele não calcula o score nem altera limites. A resposta cita a política vigente e é bloqueada quando há conflito entre fontes.

Vertex AI, Azure AI Foundry, Amazon Bedrock ou plataformas equivalentes podem apoiar o assistente. A tecnologia é secundária diante dos controles: acesso aos documentos, rastreabilidade, validação de fontes, confirmação de ações e registro de ferramentas.

A governança

O caso entra no inventário como alto impacto. Model Card, Datasheet, avaliação de impacto, testes de segurança, plano de monitoramento e canal de contestação acompanham o sistema.

Deriva, aumento de reclamações, mudança da política ou alteração relevante nos dados disparam reavaliação. A implantação deixa de ser ponto final e passa a ser o início de uma fase contínua de observação.

O aprendizado do caso

A ACME não transforma XAI em selo de confiança. Usa explicações para investigar, comunicar limites, revisar decisões e demonstrar responsabilidade. A confiança nasce do conjunto de evidências, não de um gráfico isolado.

18. Tecnologias e recursos para explorar

As ferramentas abaixo representam possibilidades, não uma lista obrigatória. A escolha depende de modalidade, risco, arquitetura, escala, competência disponível e necessidade de integração.

Necessidade	Tecnologias e recursos possíveis
Modelos interpretáveis	scikit-learn, statsmodels, InterpretML
Importância e efeito	scikit-learn, PyALE, InterpretML
Explicações locais e globais	SHAP, LIME, Alibi Explain
Contrafactuais	DiCE, Alibi Explain, CARLA
Redes neurais e visão	Captum, tf-explain, Grad-CAM, Xplique
Métricas de explicação	Quantus, Xplique, Captum
Justiça	Fairlearn, AI Fairness 360, Responsible AI Dashboard
Documentação e registro	MLflow, model registries, catálogos de dados
Monitoramento	Evidently AI, WhyLabs, Arize, Fiddler
RAG e orquestração	LangChain, LlamaIndex, Vertex AI, Azure AI Foundry, Amazon Bedrock
Avaliação de GenAI	RAGAS, TruLens, DeepEval, LangSmith
Observabilidade de aplicações	OpenTelemetry, Langfuse, Arize Phoenix
Governança e risco	GRC, inventários de IA, workflows, NIST AI RMF e ISO/IEC 42001
Nuvem responsável	SageMaker Clarify, Microsoft Responsible AI, Google Cloud Responsible AI

Nenhuma ferramenta substitui a definição do problema, a qualidade dos dados, a validação ou a responsabilidade. Ela pode automatizar partes do trabalho, padronizar evidências e reduzir esforço operacional.

Quando a pergunta é conceitual

- NISTIR 8312: quatro princípios de XAI e diferenças entre públicos [2].
- *Interpretable Machine Learning*: visão ampla de métodos e limitações [16].
- Artigos de SHAP, LIME e contrafactuais [6][7][10].

Quando a pergunta é governança

- NIST AI RMF e Playbook [3].
- ISO/IEC 42001 [12].
- Princípios da OCDE e recomendação da UNESCO [13][14].
- Model Cards e Datasheets [8][11].
-

Quando a pergunta é GenAI

- NIST AI 600-1 para riscos de IA generativa [20].
- OWASP Top 10 para aplicações com LLM [21].
- Orientações de segurança, avaliação de fontes, RAG e acesso a ferramentas.

Quando a pergunta é jurídica

- Texto oficial da LGPD [4].
- Texto oficial do EU AI Act [9].
- Orientação especializada conforme jurisdição, setor e papel da organização.

Palavra Final

XAI é trazer a humanidade de volta as decisões, em épocas que estamos confiando nas máquinas para tomar decisões, lembremo-nos que estas aprenderam com humanos.

Explicar uma IA não significa traduzir cada cálculo para linguagem comum. Significa oferecer evidências suficientes para compreender o comportamento, reconhecer limites, investigar erros e sustentar decisões responsáveis.

A confiança não nasce da fluência, da complexidade ou da estética de um gráfico. Ela se forma quando fontes, contexto, método, limites e responsabilidade podem ser vistos em conjunto.

A IA estima. A organização decide. Pessoas respondem.

19. Referências

1. DARPA. Explainable Artificial Intelligence (XAI). Disponível em: <https://www.darpa.mil/research/programs/explainable-artificial-intelligence>. Acesso em: 23 set. 2026.
2. NIST. Four Principles of Explainable Artificial Intelligence — NISTIR 8312. 2021. Disponível em: <https://nvlpubs.nist.gov/nistpubs/ir/2021/NIST.IR.8312.pdf>. Acesso em: 23 set. 2026.
3. NIST. Artificial Intelligence Risk Management Framework — AI RMF 1.0. 2023. Disponível em: <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.100-1.pdf>. Acesso em: 23 set. 2026.
4. BRASIL. Lei nº 13.709/2018 — Lei Geral de Proteção de Dados Pessoais. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 23 set. 2026.
5. SCIKIT-LEARN. Permutation Feature Importance. Disponível em: https://scikit-learn.org/stable/modules/permutation_importance.html. Acesso em: 23 set. 2026.
6. LUNDBERG, S. M.; LEE, S.-I. A Unified Approach to Interpreting Model Predictions. NeurIPS, 2017. Disponível em: <https://arxiv.org/abs/1705.07874>. Acesso em: 23 set. 2026.
7. RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. Why Should I Trust You? Explaining the Predictions of Any Classifier. KDD, 2016. Disponível em: <https://arxiv.org/abs/1602.04938>. Acesso em: 23 set. 2026.
8. MITCHELL, M. et al. Model Cards for Model Reporting. FAT*, 2019. Disponível em: <https://arxiv.org/abs/1810.03993>. Acesso em: 23 set. 2026.
9. UNIÃO EUROPEIA. Regulamento (UE) 2024/1689 — Artificial Intelligence Act. Disponível em: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj/eng>. Acesso em: 23 set. 2026.
10. WACHTER, S.; MITTELSTADT, B.; RUSSELL, C. Counterfactual Explanations without Opening the Black Box. 2017. Disponível em: <https://arxiv.org/abs/1711.00399>. Acesso em: 23 set. 2026.
11. GEBRU, T. et al. Datasheets for Datasets. Communications of the ACM, 2021. Disponível em: <https://arxiv.org/abs/1803.09010>. Acesso em: 23 set. 2026.
12. ISO. ISO/IEC 42001:2023 — Artificial Intelligence Management Systems. Disponível em: <https://www.iso.org/standard/42001>. Acesso em: 23 set. 2026.
13. OECD. Recommendation on Artificial Intelligence / OECD AI Principles. Disponível em: <https://legalinstruments.oecd.org/en/instruments/oecd-legal-0449>. Acesso em: 23 set. 2026.
14. UNESCO. Recommendation on the Ethics of Artificial Intelligence. 2021. Disponível em: <https://www.unesco.org/en/legal-affairs/recommendation-ethics-artificial-intelligence>. Acesso em: 23 set. 2026.
15. SHAP. TreeExplainer Documentation. Disponível em: <https://shap.readthedocs.io/en/latest/generated/shap.TreeExplainer.html>. Acesso em: 23 set. 2026.
16. MOLNAR, C. Interpretable Machine Learning. Disponível em: <https://christophm.github.io/interpretable-ml-book/>. Acesso em: 23 set. 2026.
17. ADEBAYO, J. et al. Sanity Checks for Saliency Maps. NeurIPS, 2018. Disponível em: <https://arxiv.org/abs/1810.03292>. Acesso em: 23 set. 2026.
18. SLACK, D. et al. Fooling LIME and SHAP: Adversarial Attacks on Post hoc Explanation Methods. AIES, 2020. Disponível em: <https://www.aies-conference.com/2020/wp-content/papers/174.pdf>. Acesso em: 23 set. 2026.
19. ICO; THE ALAN TURING INSTITUTE. Explaining Decisions Made with AI. Disponível em: <https://www.gov.uk/data-ethics-guidance/explaining-decisions-made-with-ai>. Acesso em: 23 set. 2026.
20. NIST. Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile — NIST AI 600-1. 2024. Disponível em: <https://doi.org/10.6028/NIST.AI.600-1>. Acesso em: 23 set. 2026.
21. OWASP. Top 10 for LLM Applications 2025. Disponível em: <https://owasp.org/www-project-top-10-for-large-language-model-applications/assets/PDF/OWASP-Top-10-for-LLMs-v2025.pdf>. Acesso em: 23 set. 2026.
22. SCIKIT-LEARN. Probability Calibration. Disponível em: <https://scikit-learn.org/stable/modules/calibration.html>. Acesso em: 23 set. 2026.
23. AMAZON WEB SERVICES. SageMaker Clarify. Disponível em: <https://docs.aws.amazon.com/sagemaker/latest/dg/clarify-configure-processing-jobs.html>. Acesso em: 23 set. 2026.
24. MICROSOFT. Responsible AI Dashboard. Disponível em: <https://learn.microsoft.com/en-us/azure/machine-learning/concept-responsible-ai-dashboard>. Acesso em: 23 set. 2026.
25. GOOGLE CLOUD. Responsible AI. Disponível em: <https://cloud.google.com/responsible-ai>. Acesso em: 23 set. 2026.

26. RUDIN, C. Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead. *Nature Machine Intelligence*, v. 1, p. 206–215, 2019. Disponível em: <https://arxiv.org/abs/1811.10154>. Acesso em: 23 set. 2026.
27. JAIN, S.; WALLACE, B. C. Attention is not Explanation. *NAACL*, 2019. Disponível em: <https://arxiv.org/abs/1902.10186>. Acesso em: 23 set. 2026.
28. LEWIS, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS*, 2020. Disponível em: <https://arxiv.org/abs/2005.11401>. Acesso em: 23 set. 2026.
29. TURPIN, M. et al. Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting. *NeurIPS*, 2023. Disponível em: <https://arxiv.org/abs/2305.04388>. Acesso em: 23 set. 2026.
30. KLEINBERG, J.; MULLAINATHAN, S.; RAGHAVAN, M. Inherent Trade-Offs in the Fair Determination of Risk Scores. *ITCS*, 2017. Disponível em: <https://arxiv.org/abs/1609.05807>. Acesso em: 23 set. 2026.
31. LAUX, J.; RUSCHEMEIER, H. Automation Bias in the AI Act: On the Legal Implications of Attempting to De-Bias Human Oversight of AI. *European Journal of Risk Regulation*, v. 16, p. 1519–1534, 2025. Disponível em: <https://arxiv.org/abs/2502.10036>. Acesso em: 23 set. 2026.
32. CREATIVE COMMONS. Atribuição 4.0 Internacional (CC BY 4.0). Disponível em: <https://creativecommons.org/licenses/by/4.0/deed.pt-br>. Acesso em: 23 set. 2026.
33. BRASIL. Lei nº 9.610, de 19 de fevereiro de 1998 — Lei de Direitos Autorais. Disponível em: https://www.planalto.gov.br/ccivil_03/leis/l9610.htm. Acesso em: 23 set. 2026.
34. PERPLEXITY AI. Terms of Service. Disponível em: <https://www.perplexity.ai/hub/legal/terms-of-service>. Acesso em: 23 set. 2026.

20. Créditos e licença

Autor, curador e responsável editorial: Vladimir Cruz.

Apoio à pesquisa, estruturação e revisão textual: Perplexity AI. O conteúdo foi selecionado, revisado e validado pelo autor.

Licença: este material é disponibilizado sob a licença Creative Commons Atribuição 4.0 Internacional — CC BY 4.0. É permitido compartilhar e adaptar o conteúdo, inclusive para fins comerciais, desde que seja atribuído o crédito adequado, fornecido o link da licença e indicadas as alterações realizadas [32].

Forma sugerida de atribuição: CRUZ, Vladimir. Explainable AI (XAI): da resposta convincente à decisão defensável. 2026. Licença CC BY 4.0. Apoio à pesquisa, estruturação e revisão textual: Perplexity AI.

A licença aplica-se ao conteúdo original deste guia. Materiais, marcas, documentos, imagens e trechos de terceiros permanecem sujeitos às respectivas licenças e condições de uso.